

Rapport final – Pipeline complet de préparation de données

Détection de fraude bancaire – Intelligence Artificielle

1. Introduction

Ce rapport présente un pipeline complet de préparation de données pour la détection de fraude bancaire, dans le cadre du cours Initiation à l'Intelligence Artificielle. Le projet met l'accent sur la qualité des données, le feature engineering, la gestion du déséquilibre de classes et l'interprétation des résultats.

2. Jeu de données

Le dataset Credit Card Fraud Detection (Kaggle) contient environ 284 800 transactions avec 31 variables. La variable cible Class indique si une transaction est frauduleuse ou non. Le taux de fraude est d'environ 0,17 %, ce qui rend le problème fortement déséquilibré.

3. Exploration des données

La distribution des classes montre une domination extrême des transactions normales. L'analyse des montants révèle une forte asymétrie et de nombreux outliers. Les graphiques fournis dans le PDF montrent également que certaines heures présentent un taux de fraude plus élevé.

4. Feature engineering

Deux variables ont été ajoutées : l'heure de la transaction (Hour) et un indicateur de petit montant (is_small_amount). Ces variables apportent une information pertinente pour la détection de fraude.

5. Transformations

Les transformations appliquées incluent log1p sur le montant, un RobustScaler pour gérer les outliers et une transformation Yeo-Johnson sur certaines variables asymétriques. Toutes les transformations sont apprises uniquement sur le jeu d'entraînement.

6. Modélisation

Un modèle de régression logistique est utilisé comme modèle de référence. Plusieurs stratégies sont comparées : baseline, class_weight, RandomUnderSampler et SMOTE.

7. Résultats graphiques

Les courbes ROC et Precision-Recall, ainsi que les matrices de confusion présentées dans le PDF, montrent que le modèle baseline offre le meilleur compromis précision / PR-AUC. Les méthodes de rééchantillonnage améliorent le rappel mais génèrent beaucoup de faux positifs.

8. Ajustement du seuil

L'ajustement du seuil de décision pour SMOTE permet de réduire fortement les faux positifs tout en conservant un rappel élevé, ce qui est essentiel dans un contexte métier.

9. Conclusion

Ce projet démontre l'importance de la préparation des données dans un contexte réel de détection de fraude. Le choix du modèle et du seuil dépend fortement des objectifs métier, entre minimisation des fausses alertes et maximisation de la détection des fraudes.